RÉPUBLIQUE ALGÉRIENNE DÉMOCRATIQUE ET POPULAIRE

MINISTÈRE DE L'ENSEIGNEMENT SUPÉRIEUR ET DE LA RECHERCHE SCIENTIFIQUE

ÉCOLE NATIONALE POLYTECHNIQUE
Spécialité : Génie Industriel
Option : Data Science et Intelligence Artificielle

Travaux Pratiques N°5 : Détection du langage offensif en Arabizi

Destinataire :
Mme. Esma BENDIAB

Réalisé par :
Amel RAHIM et Hadil OUSSENA

Année Universitaire : 2025/2026

Contexte et objectifs

Les réseaux sociaux arabophones contiennent une proportion importante de messages offensants ou haineux, souvent rédigés en Arabizi, c'est-à-dire une romanisation informelle des dialectes arabes mélangeant chiffres, français, anglais et arabe dialectal. Cette écriture ne respecte pas de norme orthographique et présente une forte variation lexicale, ce qui rend la détection automatique du langage offensif particulièrement difficile.

L'objectif de ce travail pratique est de mettre en place un pipeline complet de classification de texte pour la détection du langage offensif en Arabizi, puis de comparer un ensemble de modèles classiques à un modèle BERT-like (DziriBERT) sur un corpus annoté, en tenant compte de la variation dialectale (algérien vs libanais).

Les objectifs pédagogiques sont :

- Comprendre les spécificités linguistiques de l'Arabizi et du langage offensif sur les réseaux sociaux.
- Construire une chaîne complète de traitement : prétraitement, représentation, apprentissage, évaluation.
- Comparer un classifieur classique à un modèle pré-entraîné de type BERT.
- Réaliser une analyse qualitative des erreurs et proposer des pistes d'amélioration.

Description des données

Le fichier CSV `Arabizi-Off_Lang_Dataset.csv` a été téléchargé depuis GitHub, puis intégré tel quel dans le notebook de TP pour l'exploration, le prétraitement et l'entraînement des modèles.

Il combine des messages en Arabizi libanais et algérien annotés en deux classes : Offensive et Non-Offensive et comporte au minimum les colonnes id, text, label, dialect, où dialect vaut Algerian ou Lebanese.

Après chargement et nettoyage des valeurs manquantes, le corpus final contient 7383 messages, dont environ 79,3% non offensifs et 20,7% offensifs, ce qui montre un déséquilibre important en faveur de la classe majoritaire. Les messages algériens sont légèrement plus nombreux que les messages libanais (4249 vs 3134).

Quelques exemples anonymisés montrent la diversité des formes d'Arabizi : mélange de français et d'arabe dialectal, utilisation massive de chiffres (3, 7, 9) pour représenter des phonèmes arabes, présence d'emojis et de code-switching entre plusieurs langues dans un même message.

1 Prétraitement et modèles classiques

— Importation des bibliothèques.
— Chargement du dataset.
— Prétraitement initial et analyse descriptive : calcul de la taille du corpus, de la proportion de chaque classe et de la répartition par dialecte, ainsi que l'affichage de quelques exemples représentatifs.

Prétraitement du texte

Un prétraitement léger a été appliqué à la colonne text qui produit une nouvelle colonne `text_clean`, afin de normaliser le texte tout en conservant l'information portée par les variantes d'orthographe et les chiffres typiques de l'Arabizi. Les principales étapes sont :

— Suppression des URLs et des handles, qui ne sont pas informatifs pour la détection du caractère offensif.
— Remplacement de toute ponctuation ou symbole non alphanumérique par des espaces, puis normalisation des espaces afin d'obtenir une séquence propre de tokens.

Représentation TF-IDF et apprentissage

Les données sont d'abord divisées en trois sous-ensembles : apprentissage, développement et test, avec un split 70% / 15% / 15%, en stratifiant sur la classe label afin de conserver la proportion de messages offensifs et non offensifs dans chaque partition.

Les messages sont ensuite représentés à l'aide d'un TF-IDF de n-grammes de caractères, paramétré avec analyzer="char", une fenêtre 3,5, min_df=3 et max_features=5000, ce qui permet de capturer la morphologie spécifique de l'Arabizi et de rester robuste aux fautes d'orthographe et aux variations de translittération.

Sur ces vecteurs TF-IDF, plusieurs modèles classiques sont entraînés :

— Naive Bayes Multinomial et Complement.
— Régression Logistique.
— SVM linéaire.
— Random Forest.

Pour chaque modèle, un entraînement est réalisé, puis des prédictions sont générées. Les métriques suivantes sont calculées : accuracy, precision, recall et F1-Score, et stockées dans un DataFrame.

Les principaux résultats sur le jeu de test (1108 messages) sont les suivants :

— Multinomial NB : Accuracy = 0,84, F1-Score = 0,69.
— Complement NB : Accuracy = 0,75, F1-Score = 0,69.
— Régression Logistique : Accuracy = 0,85, F1-Score = 0,69.
— Linear SVM : Accuracy = 0,85, F1-Score = 0,74 (meilleur modèle classique global).
— Random Forest : Accuracy = 0,85, F1-Score = 0,70.

Résultats par dialecte et analyse des erreurs

Pour mesurer l'impact de la variation dialectale, une fonction dédiée calcule le F1-score séparément sur les messages algériens et libanais. Cette évaluation est appliquée à chacun

des modèles classiques, ce qui permet de comparer directement leurs performances sur les deux dialectes :

— Sur l'algérien, les F1 varient autour de 0,68–0,73, avec la SVM qui atteint = 0,73.
— Sur le libanais, les F1 sont plus faibles, autour de 0,52–0,57, ce qui montre que les modèles classiques ont plus de mal à généraliser sur ce dialecte.

La SVM linéaire, qui obtient les meilleurs scores globaux, fait ensuite l'objet d'une analyse d'erreurs plus fine : une matrice de confusion est tracée et qui montre que la majorité des erreurs sont des faux négatifs (messages offensifs classés non offensifs). Pour approfondir, un DataFrame errors est construit puis un échantillon de dix messages est examiné afin d'illustrer les insultes ou propos agressifs que la SVM ne parvient pas à détecter.

2 DziriBERT

Cette partie consiste à affiner un modèle pré-entraîné DziriBERT via l'API transformers de HuggingFace. Le tokenizer est appliqué sur le texte brut puis un mapping d'étiquettes "Non-Offensive" : 0, "Offensive" : 1 est défini pour encoder les labels du corpus. Le modèle est entraîné pendant 3 epochs avec un batch size de 16.

Les courbes de loss montrent une décroissance régulière de la loss d'entraînement qui montre que le modèle s'adapte de mieux en mieux aux exemples du train et un minimum de loss de validation autour de la 2ème epoch, puis une légère remontée suggérant le début d'overfitting.

Résultats globaux et par dialecte

— Accuracy = 0,87.
— F1-Score = 0,79, avec une précision = 0,81 et un rappel = 0,78.

Par dialecte, DziriBERT atteint un F1 = 0,79 sur les messages algériens et = 0,54 sur les messages libanais.

Tableau comparatif des résultats (modèles classiques vs BERT).

Modèle	**Accuracy**	**Macro-F1**	**F1 DZ**	**F1 LB**
`Multinomial NB`	0,843	0,695	0,681	0,524
`Complement NB`	0,755	0,689	0,617	0,536
`Logistic Regression`	0,849	0,686	0,680	0,485
`Linear SVM`	0,853	0,743	0,734	0,570
`Random Forest`	0,850	0,700	0,696	0,517
`DziriBERT`	0,869	0,793	0,793	0,538

Table 1 – Tableau comparatif des résultats

3 Analyse d'erreurs

Faux positifs / faux négatifs par dialecte

Pour la SVM :

— DZ : sur 631 exemples, environ 6% de FP et 15% de FN, ce qui signifie qu'un message offensif sur six est manqué.

— LB : sur 477 exemples, 1,3% de FP et 4,8% de FN, mais le corpus libanais étant plus petit, le modèle reste moins stable.

Pour DziriBERT :

— DZ : sur 631 exemples, 8,4% de FP et 9,5% de FN, la proportion de faux négatifs diminuant nettement par rapport à la SVM.

— LB : sur 477 exemples, 1,7% de FP et 5,0% de FN, les erreurs restant concentrées sur la classe offensive libanaise.

Ces chiffres confirment que DziriBERT réduit les faux négatifs offensifs algériens, ce qui est positif dans un contexte de modération, au prix d'une légère augmentation de faux positifs.

Analyse d'erreurs

En inspectant une vingtaine de faux négatifs de la SVM, on observe de nombreuses insultes explicites envers l'État, des attaques contre des régions ou des groupes, ainsi que des moqueries dirigées contre des personnes ou leur famille, toutes classées Non-Offensive par le modèle.

— Insultes politiques / sociales (DZ) : message qui insulte l'État ou "la doula" avec un vocabulaire vulgaire et des références à des maladies ou au "colonialisme", mais que la SVM classe Non-Offensive (Ligne 7068).

Interprétation : le modèle ne capte pas bien certaines insultes écrites en Arabizi avec des jeux de mots ou des abréviations.

Même si DziriBERT réduit globalement le nombre de faux négatifs (surtout en DZ), il reste fragile sur ce type de messages. Par exemple, les lignes 4442, 4257...

Dans plusieurs cas, le modèle classique SVM ne parvient pas à détecter des messages offensifs dont la toxicité repose davantage sur le contexte ou sur des références implicites (par exemple à une "mafia", à une personne ou à un groupe précis), sans gros mot isolé clairement identifiable. DziriBERT, qui tient compte de l'ensemble de la phrase et de la relation entre les mots, classe correctement ces messages comme offensifs, ce qui montre sa meilleure capacité à capturer le sens global plutôt que de simples motifs de caractères.

4 Discussion

Ce travail a montré qu'un pipeline classique permet déjà d'obtenir de bonnes performances pour la détection du langage offensif en Arabizi, avec une accuracy autour de 0,85 mais un Macro-F1 plus limité à cause de la difficulté à bien capturer la classe offensive minoritaire et la diversité dialectale. L'analyse par dialecte met en évidence de meilleurs scores sur l'algérien que sur le libanais, ce qui suggère que les modèles classiques exploitent mieux les formes fréquentes du DZ que les formulations plus variées du LB.

L'ajout de DziriBERT apporte un gain clair : le Macro-F1 global augmente jusqu'à environ 0,79 et le F1 sur le dialecte algérien progresse nettement, tout en réduisant le taux de faux négatifs offensifs, ce qui est particulièrement important dans une optique de modération. Cependant, les résultats sur le dialecte libanais restent plus modestes et les courbes de loss montrent le début d'un sur-apprentissage, ce qui indique que la couverture dialectale et la taille du corpus LB restent des points sensibles.

L'analyse d'erreurs révèle enfin plusieurs limites communes aux deux approches : messages offensifs implicites ou sarcastiques, mélange complexe de langues et d'abréviations, et cas où le contexte social ou politique est nécessaire pour comprendre l'offense. Dans l'ensemble, ce TP illustre bien l'intérêt des modèles BERT pour mieux saisir le sens des messages en Arabizi, tout en montrant que la qualité et la diversité des données, la prise en compte des dialectes et le traitement du déséquilibre de classes restent essentiels pour construire des systèmes robustes en conditions réelles.